Orange en Minería de Datos: Tutorial resumido

Prof. Dr. Jorge Zavaleta

Programa de Doctorado en Estadística Matemática Aplicada

Universidad Nacional de Tumbes

zavaleta.jorge@gmail.com

Introducción

Orange es una plataforma visual para el análisis de datos que permite construir flujos de trabajo mediante la conexión de componentes funcionales llamados *widgets*. Cada widget representa una operación específica dentro del ciclo analítico – como la carga de datos, el preprocesamiento, el modelado, la evaluación o la visualización – y su integración en un flujo facilita la comprensión de los procesos de minería de datos.

El desarrollo de aplicaciones en Orange se realiza sobre un lienzo gráfico (**Canvas**), donde el usuario organiza y conecta los widgets para formar un flujo coherente de análisis. La comunicación entre ellos se establece mediante puertos de entrada y salida: los datos se transmiten desde el puerto de salida del widget ubicado a la derecha hacia el puerto de entrada del siguiente, situado a la izquierda. La figura 1 presenta la pantalla inicial del Orange.

Cuando existe incompatibilidad entre los tipos de datos que circulan entre dos widgets, Orange lo señala mediante una línea de conexión en color rojo, indicando la necesidad de revisar la estructura del flujo o el tipo de información transferida.

Este tutorial presenta un procedimiento estructurado en seis pasos que guía al estudiante desde la importación inicial del conjunto de datos (*dataset*) hasta la construcción y evaluación de modelos supervisados y no supervisados. También incluye técnicas de validación y opciones de extensión mediante programación en Python, proporcionando una visión integral del funcionamiento de los widgets y de la lógica que sustenta los flujos analíticos en Orange.

Paso 1: Carga y Verificación de Datos

1. **Agregar el widget de origen.** Arrastre el widget **File** al **Canvas** desde la sección **Data**.

2. **Cargar el conjunto de datos.** Haga doble clic en **File** para seleccionar un archivo local (`.xlsx`, `.csv`, `.tab`) o utilice uno de los conjuntos de datos incluidos en Orange,

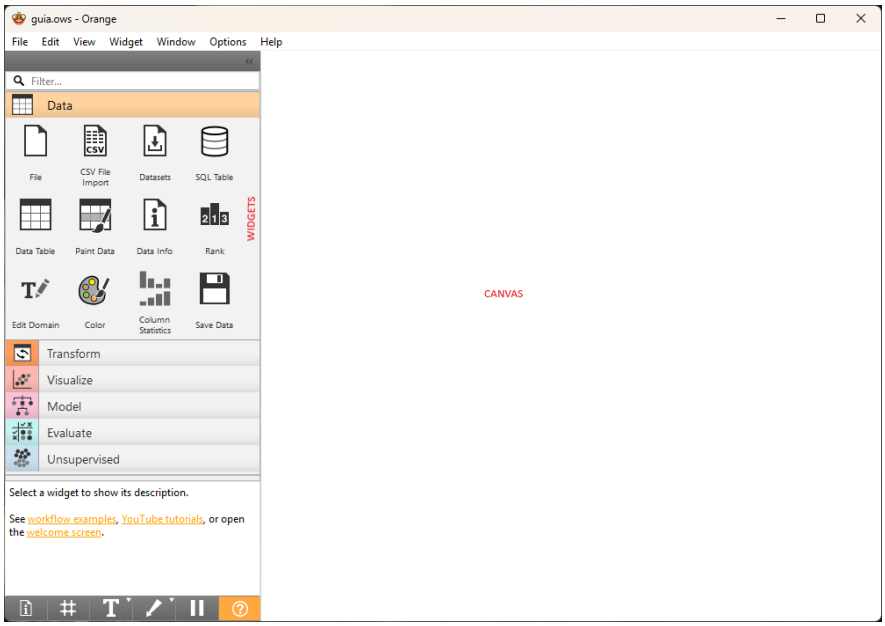


Figura 1: Pantalla inicial del Orange

como *iris*, *titanic* o *brown-selected*. También es posible ingresar la URL de una hoja de cálculo pública de Google Sheets.

3. **Configurar los roles de las columnas.** Verifique que los atributos cuantitativos estén definidos como **Numeric** y los cualitativos como **Categorical**. Identifique la variable objetivo (**target class**) y marque como **meta** aquellos atributos descriptivos que no deben participar en el proceso predictivo., como mostrado en la figura 2.

4. **Previsualización.** Arrastre el widget **Data Table** al **Canvas** desde la sección **Data** y colóquelo a la derecha del widget **File**. Conecte la salida del widget **File** al **Data Table** para inspeccionar la estructura tabular del conjunto de datos.

Paso 2: Exploración Visual y Preprocesamiento

1. **Análisis exploratorio.** Arrastre el widget **Scatter Plot** desde la sección **Visualize** y colóquelo a la derecha del widget **Data Table**. Conecte la salida del widget **Data Table** al widget **Scatter Plot** y haga doble clic sobre este para examinar las relaciones entre variables, identificar patrones de dispersión y detectar posibles agrupamientos naturales, como se observa en la figura 3.

2. **Limpieza e imputación.** Si existen valores faltantes, utilice el widget **Preprocess** de la sección **Transform** o componentes específicos, como el widget **Impute** de la sección **Transform**, para tratarlos adecuadamente.

3. **Escalado y selección de atributos.** Hacer doble clic sobre el widget **Preprocess** para activar las diferentes herramientas de preprocesamiento y seleccione la opción

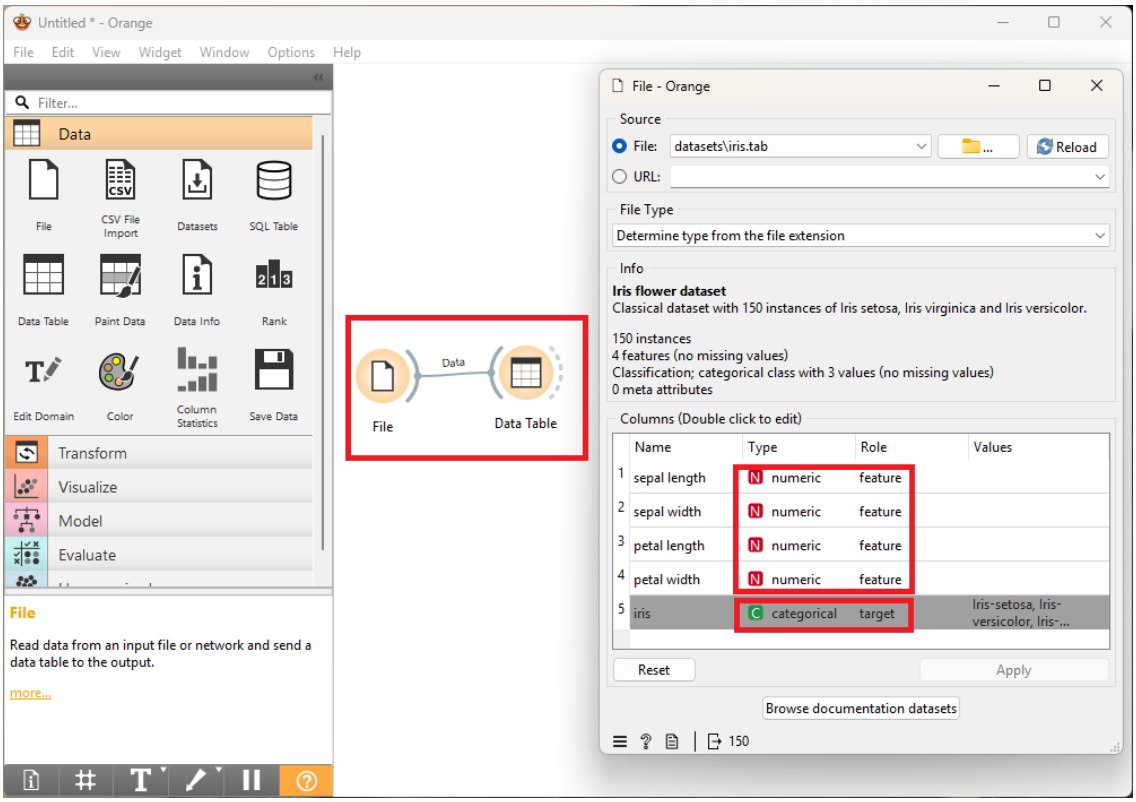


Figura 2: Carga y verificación de datos

de normalización (**Normalize Features**) para estandarizar las características ($\mu = 0, \sigma^2 = 1$), como se observa en la figura 3. Elija la herramienta más adecuada para su estudio. Por ejemplo, puede utilizar la opción de selección de características (**Select Relevant Features**) con métricas como la Ganancia de Información (**Information Gain**) para conservar únicamente los atributos más relevantes.

Paso 3: Construcción y Entrenamiento de Modelos

1. **Selección de algoritmos.** A partir de la sección **Model**, seleccione y arrastre al widget **Canvas** los widgets correspondientes a los clasificadores o regresores que desea evaluar, tales como **Tree**, **Logistic Regression**, **SVM**, **Naive Bayes**, **Random Forest**, entre otros. Luego conecte la salida del widget **File** al widget **Tree**, tal como se observa en la figura 4.

2. **Comprender el rol del Learner.** En Orange, cada widget de algoritmo actúa como un **Learner**: recibe datos, aprende patrones y produce un modelo entrenado. La salida del widget **Tree** puede conectarse a **Tree Viewer**, ubicado de la sección **Visualize**, para visualizar la estructura jerárquica del árbol y las reglas inferidas, tal como se observa en la figura 4.

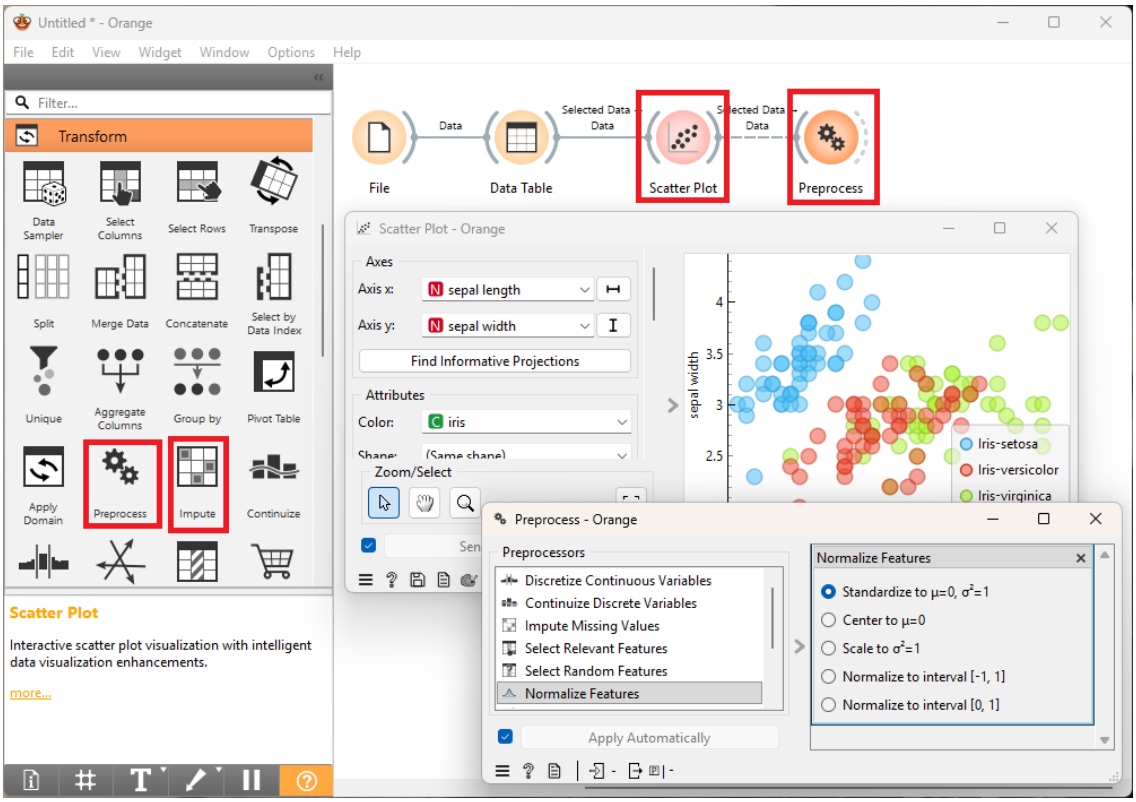


Figura 3: Exploración Visual y Preprocesamiento

Paso 4: Evaluación y Validación Cruzada

1. **Validación del rendimiento.** A partir de la sección **Evaluate**, arrastre el widget **Test and Score** al widget **Canvas**. Conecte la salida del conjunto de datos **File** a la entrada del widget **Test and Score** y la salida del widgets **Learner (Tree)** a la entrada del widget **Test and Score**, como observado en la figura 5.

2. **Análisis de métricas.** Configure la validación cruzada (por ejemplo, 10 *folds*) para obtener estimaciones robustas. Evalúe métricas como la Precisión de Clasificación (CA) y el Área Bajo la Curva ROC (AUC), como ilustrado en la figura 5.

3. **Diagnóstico de errores.** Conecte la salida del widget **Test and Score** a la entrada del widget **Confusion Matrix**, como se ilustra en la figura 5. Analice los falsos positivos y falsos negativos, y utilice el widget **Scatter Plot** para investigar visualmente las instancias mal clasificadas.

4. **Predicción sobre nuevos datos.** A partir de la sección **Evaluate**, arrastre el widget **Predictions** al **Canvas**. Conecte la salida del modelo entrenado (por ejemplo, **Tree**) a una de las entradas del widget **Predictions**. Luego, desde la sección **Data**, adicione un nuevo dataset (conjunto de prueba) arrastrando el widget **File** al **Canvas** y conecte su salida a la entrada del widget **Predictions**. En el proceso de predicción, **algunas estimaciones fallan** cuando el modelo asigna una clase distinta de la clase real (el

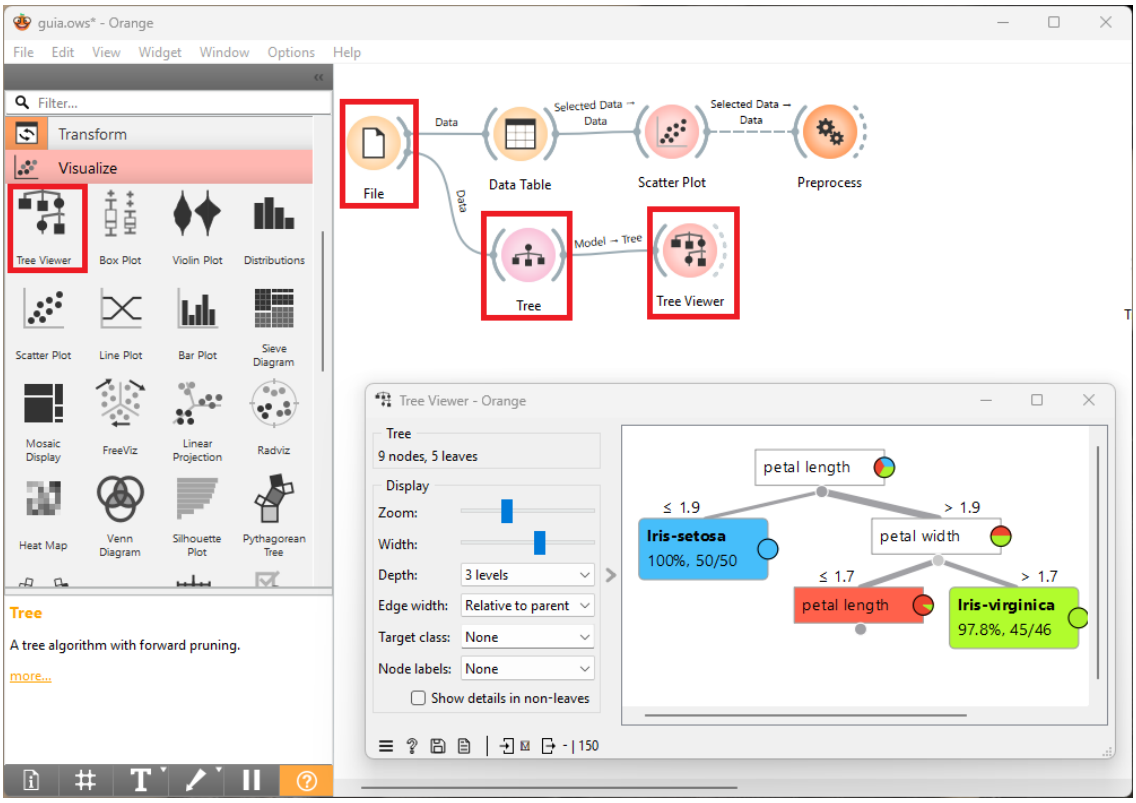


Figura 4: Construcción y Entrenamiento de Modelos Supervisados

widget **Predictions** presentará un circulo de color rojo con una 'x'). Esto indica que ciertas instancias fueron clasificadas de manera incorrecta, generando errores como falsos positivos o falsos negativos. Estos desaciertos no significa que el modelo esté defectuoso, más bien reflejan sus limitaciones naturales y la incertidumbre inherente al aprendizaje automático, donde es habitual que el rendimiento no sea perfecto en todos los casos, como observado en la figura 6.

Paso 5: Aplicaciones No Supervisadas (Clustering)

1. **Cálculo de distancias.** A partir de la sección **Unsupervised**, arrastre el widget **Distances** al **Canvas**. Conecte la salida de widget **File** a una entrada de **Distances** para generar matrices de similitud mediante distancia Euclidiana o Similitud de Coseno, como ilustrado en la figura 7.

2. **Agrupamiento jerárquico.** Conectar una salida del widget **Distances** con una entrada del **Hierarchical Clustering** para calcular las distancias entre las instancias y generar el **dendrograma** correspondiente. Examine el **dendrograma** y seleccione un umbral de corte (Observar el dendrograma y selecciona un punto de corte (threshold) donde los grupos se separan de forma clara. Este corte define cuántos clusters se formarán. Por ejemplo, C1, como ilustrado en la figura 7) para caracterizar los grupos mediante **Scatter Plot** (para observar la distribución de los grupos en dos dimensiones)

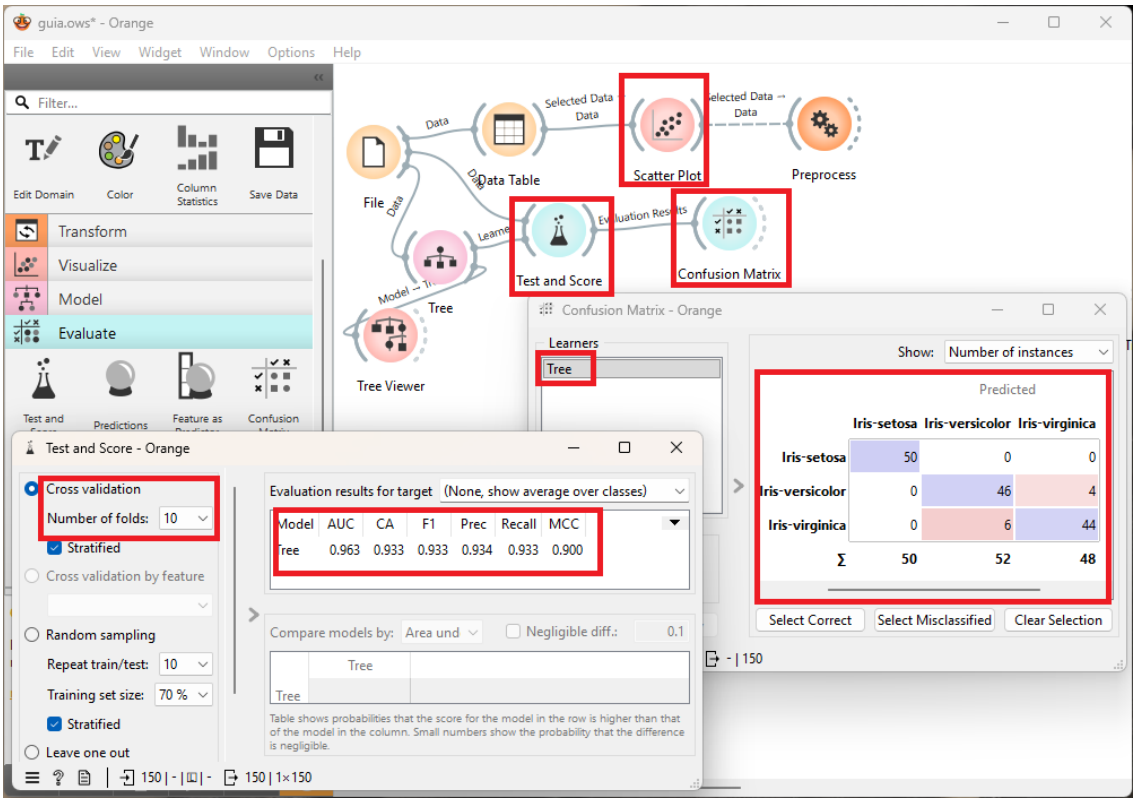


Figura 5: Evaluación y Validación Cruzada Supervisada

o **Box Plot** (para comparar variables entre los grupos y analizar sus características), como ilustrado en la figura 7.

3. **Agrupamiento con k-Means.** Desde la sección **Unsupervised**, arrastre el widget **k-Means** al **Canvas**, haga lo mismo con el widget **Silhouette Plot** de la sección **Visualize**. Luego, conecte la salida del widget **File** – por ejemplo, utilizando el dataset *iris* – a la entrada del widget **k-Means**, en seguida conecte la salida del widget **k-Means** (aplica el algoritmo de agrupamiento y asigna cada instancia a un cluster [1, 2, 3]) a la entrada del **Silhouette Plot** (recibe asignaciones y calcula la puntuación de silueta, que permite evaluar la calidad del agrupamiento [2, 3]), tal como se ilustrado en la figura 8. Evalúe la puntuación de silueta:

$$S = \frac{B - A}{\text{máx}(A, B)}$$

para determinar el número óptimo de centroides k. Esta conexión, ayuda a analizar qué valor de `k` produce clusters más coherentes y mejor separados. El valor de **S** es interpretado como:

- **S cercano a 1** – excelente agrupamiento.
- **S alrededor de 0** – punto en zona ambigua.
- **S negativo** – asignación incorrecta.

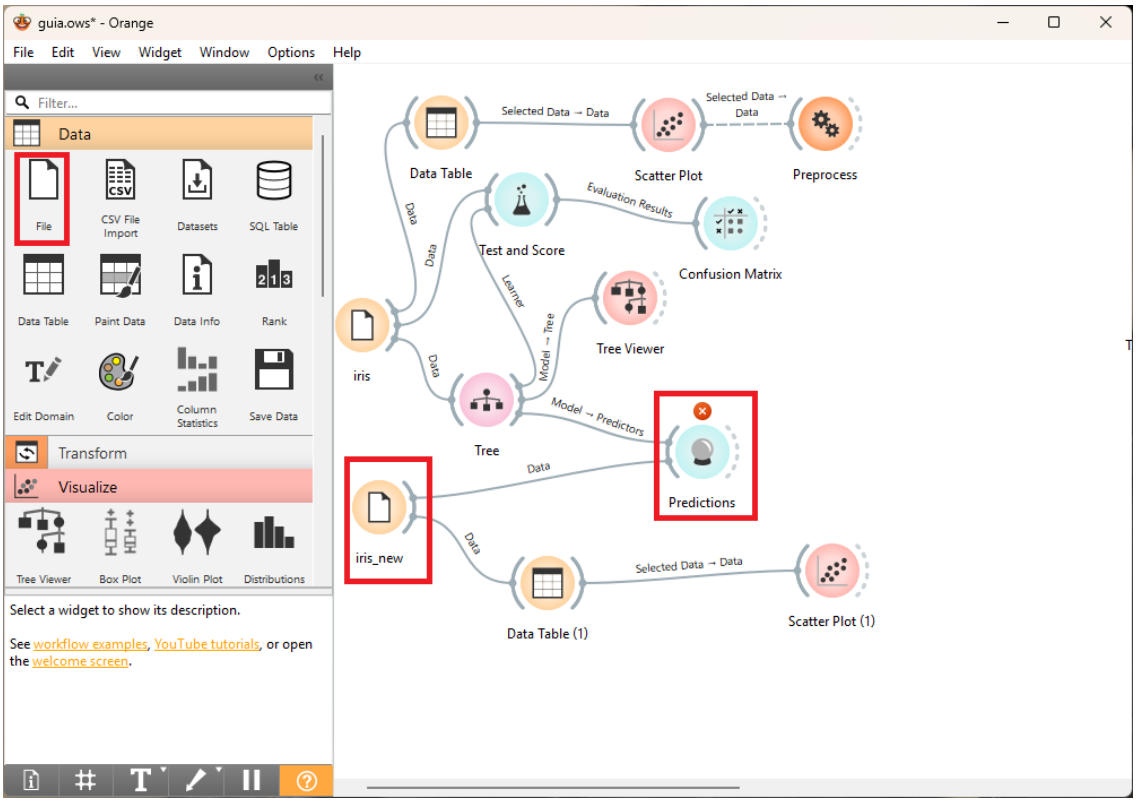


Figura 6: Predicción sobre nuevos datos

Paso 6: Extensión y Programación Avanzada

1. **Widget Python Script.** El widget **Python Script** disponible en la sección **Data** o en la sección **Prototypes** (cuando se activa desde el menú *Options* y *Add-ons* seleccionando Prototypes), permite aplicar transformaciones personalizadas directamente sobre los datos (objetos Table) dentro de la interfaz gráfica de Orange. Con este widget es posible escribir código en Python para modificar, filtrar, crear nuevas variables o generar salidas específicas que no están disponibles mediante los widgets estándar.

   En la versión 3.40.0 de Orange utilizada para este tutorial, el widget **Python Script** aparece en la sección **Transform**, pero no ejecuta ningún código debido a incompatibilidades con la versión Python instalada en el PC (Python 3.13). Este widget **Python Script** solo funciona correctamente cuando Orange se ejecuta sobre Python 3.8 o 3.9, versiones oficialmente compatibles.

2. **Librería de Python.** Para automatizar procesos fuera del entorno visual de Orange, es posible utilizar su API nativa desde Python. Para ello, basta con importar la biblioteca principal:

```
import Orange
```

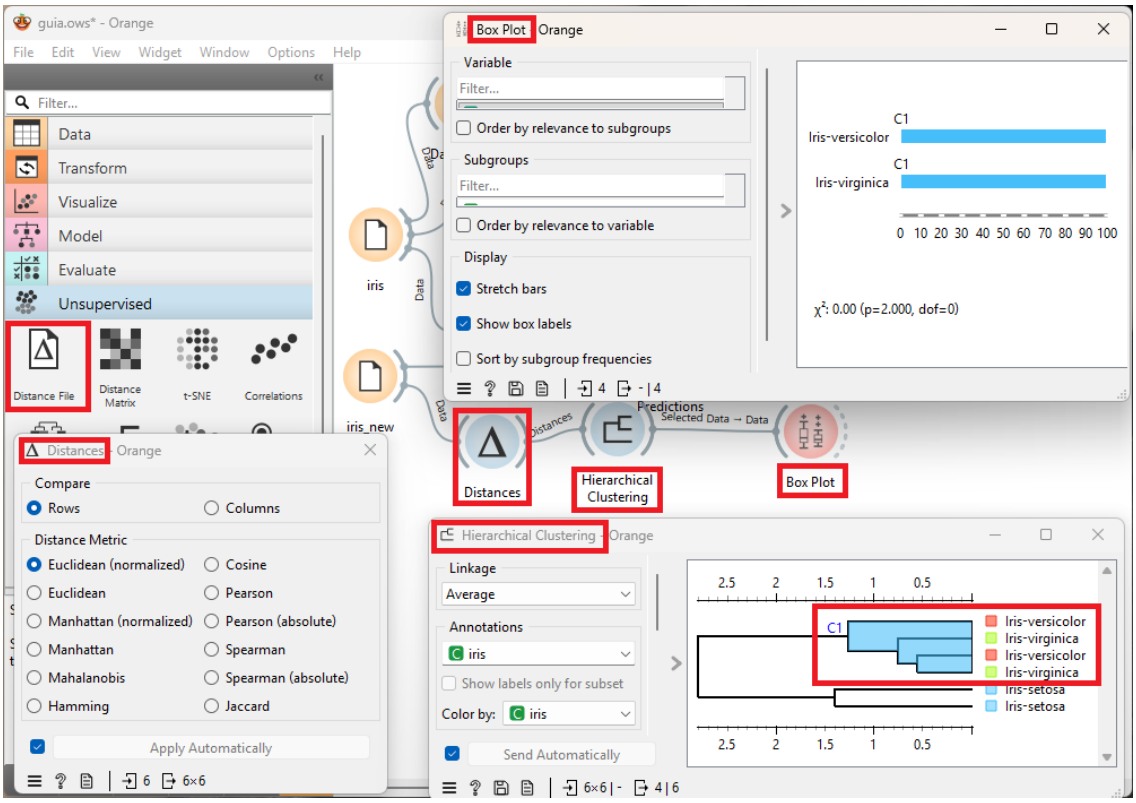


Figura 7: Aplicaciones No Supervisadas (Clustering)

La API permite cargar tablas mediante (**Orange.data.Table**), entrenar modelos, realizar transformaciones y evaluar métricas directamente desde código Python. Este enfoque combina la eficiencia del núcleo de Orange – implementado en C++ – con la flexibilidad de bibliotecas como NumPy, ofreciendo una alternativa programática a los flujos construidos en la interfaz gráfica.

El uso de Orange como herramienta de apoyo en la minería de datos resulta especialmente valioso en contextos de aprendizaje. Su interfaz visual basada en widgets permite que los estudiantes comprendan de manera intuitiva cómo se construyen los flujos de análisis, desde la carga de datos hasta la evaluación de modelos. Esta representación gráfica facilita la exploración, fomenta la curiosidad y reduce la complejidad inicial que suele acompañar a los entornos de programación tradicionales. Además, sus visualizaciones interactivas ayudan a interpretar resultados y a entender mejor el comportamiento de los algoritmos, lo que convierte a Orange en un recurso pedagógico eficaz.

No obstante, Orange también presenta algunas limitaciones que deben considerarse. Al depender de un conjunto fijo de widgets, ciertas tareas avanzadas o transformaciones específicas pueden no estar disponibles, lo que restringe la flexibilidad para quienes desean profundizar más allá de las funciones básicas. Algunas características —como el widget Python Script— pueden no estar accesibles según la versión instalada o la compatibilidad con Python, lo que dificulta la integración con flujos programáticos más complejos. Además, Orange no está diseñado para manejar grandes volúmenes de datos ni para entornos de producción, por lo que su uso se orienta principalmente a la enseñanza, la experimentación y el prototipado.

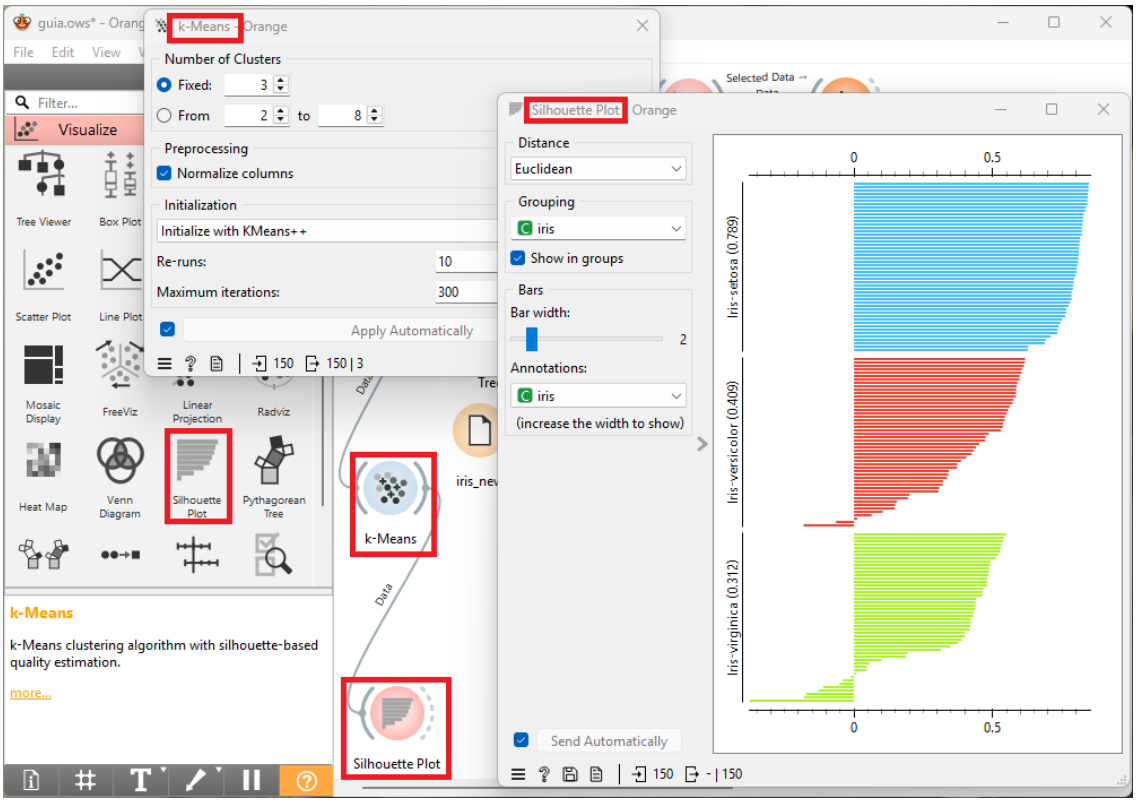


Figura 8: Agrupamiento con k-means

En resumen, Orange es una herramienta ideal para aprender los fundamentos de la minería de datos, experimentar con algoritmos y visualizar resultados de forma clara y accesible. Sus limitaciones no afectan su valor educativo, sino que más bien señalan el momento en que el estudiante puede avanzar hacia herramientas más completas o programáticas. Como punto de partida, Orange ofrece una experiencia de aprendizaje sólida, intuitiva y motivadora.

Referencias

[1] Aggarwal, Charu C., Machine Learning for Text. 2 ed, Springer International Publishing, 2022. DOI:10.1007/978-3-030-96623-2

[2] Nyamawe, A.S. et all. Practical Machine Learning, CRC Press Taylor & Francis Group, 2025

[3] Zavaleta, J., Lyra, G., Serra, S., Python para Ciência de Dados: Aplicado à Agricultura. Cerceau, 2026